



PIPELINE DATAOPS AUTOMATIZADO PARA LA PREDICCIÓN Y MITIGACIÓN DE FUGA DE CLIENTES EN TELECOMUNICACIONES

Telco Customer Churn



Integrantes:

- Fabrizio González Rodríguez
- Gary Maldonado Guzman

Nombre del Docente: Cristian Molina

Sección: 002-D

27 DE MAYO DE 2026
[GESTIÓN DE PROYECTOS IA]

Contenido

Introducción	2
Resumen Ejecutivo	2
Justificación de la Metodología Aplicada	2
Planificación del Proyecto	2
1. Alcance del Proyecto	2
2. Entregables del Proyecto	3
3. Cronograma Tentativo	3
4. Desglose del Proyecto	3
5. Hitos Técnicos	4
6. Riesgos y Estrategias de Mitigación	4
Explicación Técnica del Pipeline	4
Plan de Seguridad entorno DataOps	5
Medidas Técnicas Implementadas:	5
Diseño Técnico del sistema	6
1. Descripción técnica del sistema	6
1.1 Componentes técnicos del sistema	6
1.2 Estructura General	6
1.3 Tecnologías utilizadas	7
1.4 Relación entre componentes	7
2. Diagrama técnico	7
3. Modelo de datos básico y diccionario	8
3.1 Modelo de datos	8
3.2 Diccionario de datos	8
4. README.md	9
Estrategia de KPI de Monitoreo	9
Conclusión	9

Introducción

Este documento tiene como objetivo describir de forma técnica y estructurada el sistema desarrollado por el equipo, orientado a la predicción de abandono de clientes de la compañía de telecomunicaciones. Contiene todos los elementos necesarios para comprender, replicar y mantener la solución, sirviendo como base técnica para la implementación del pipeline de datos.

Resumen Ejecutivo

El presente proyecto aborda el fenómeno crítico de la pérdida de clientes en la industria de las telecomunicaciones utilizando un enfoque moderno de DataOps. La base de datos analizada contiene registros de 7,043 clientes distribuidos en 21 variables que describen atributos demográficos, servicios contratados y cuentas financieras.

El objetivo de la solución consiste en automatizar la extracción, tratamiento y validación de datos crudos mediante un flujo reproducible e industrializado, asegurando que los científicos de datos cuenten con variables limpias y listas para modelos predictivos de Inteligencia Artificial de forma continua.

Valor para la organización: Reducción drástica del *Time-to-Market* de los modelos analíticos, mitigación de fallos en producción mediante validación automatizada y la capacidad de identificar proactivamente a los clientes insatisfechos para desplegar campañas de retención comerciales oportunas, incrementando el valor del tiempo de vida del cliente.

Justificación de la Metodología Aplicada

Para la gestión de este proyecto se seleccionó una metodología adaptativa (Ágil - Scrum).

Esto debido a que, los proyectos de datos e inteligencia artificial se caracterizan por una alta incertidumbre exploratoria. Un enfoque rígido como el predictivo (Cascada) provocaría retrasos masivos e inconsistencias como valores nulos ocultos o tipos de datos erróneos en el archivo CSV. Es por ello que, siguiendo la estructura Scrum, se planificó un marco de 3 semanas dividido en tres Sprints semanales articulados en un Product Backlog centralizado en Monday. Esto facilita ciclos de retroalimentación inmediatos, incrementos de código potencialmente entregables e inspección automatizada constante mediante integración continua (CI).

Planificación del Proyecto

1. Alcance del Proyecto

El alcance de este proyecto comprende una solución técnica que permita predecir el abandono de clientes en la compañía de telecomunicaciones, basada en los campos de "MonthlyCharges", "TotalCharges" y "Churn". El proyecto incluye: obtención y procesamiento de datos, almacenamiento en base de datos y visualización de resultados. No incluye el despliegue de la solución en servidores cloud en tiempo real ni el desarrollo de aplicaciones web/móviles para clientes finales.

2. Entregables del Proyecto

- Documento de planificación
- Documento de diseño técnico
- Script del pipeline de datos
- Dataset limpio cargado en SQLite
- README.md actualizado
- Documento final consolidado
- Presentación del proyecto

3. Cronograma Tentativo

Se estima una duración total de 3 semanas. Cada fase tiene tareas específicas con duración estimada y entregables intermedios.

Semana 1: Configuración entorno de trabajo + Redacción del informe técnico + Desarrollo código etapa ingesta.

Semana 2: Desarrollo código etapa limpieza y transformación, validación y carga de datos + redacción de plan de seguridad.

Semana 3: Diseño de estrategias de monitoreo + Generación de evidencias + Consolidación informe técnico + Diseño de presentación de proyecto.

4. Desglose del Proyecto

1. Proyecto Terminado
 - 1.1 Planificación
 - 1.2 Diseño técnico
 - 1.2.1 Documento diseño técnico
 - 1.2.2 README
 - 1.3 Desarrollo técnico
 - 1.3.1 Ingesta de datos
 - 1.3.2 Limpieza y transformación
 - 1.3.3 Validación
 - 1.3.4 Carga de datos
 - 1.3.5 Visualización (Dashboard)
 - 1.4 Documentación y cierre
 - 1.4.1 Documento final
 - 1.4.2 Presentación final

5. Hitos Técnicos

- Hito técnico 1: Entorno y repositorio configurados + Pipeline de Ingesta desarrollado.
- Hito técnico 2: Informe técnico completo y plan de seguridad definido
- Hito técnico 3: Dataset limpio y validado, cargado en SQLite
- Hito técnico 4: Modelo Predictivo de Inteligencia Artificial (Churn) entrenado y evaluado.
- Hito técnico 5: Presentación del sistema

6. Riesgos y Estrategias de Mitigación


1. Vulneración de datos sensibles → Encriptación de customerID
2. Falta de reproducibilidad de la solución → Configuración de entorno de trabajo
3. Retrasos → Revisión semanal de avance según cronograma

Explicación Técnica del Pipeline

Para llevar a cabo esta solución la arquitectura utilizada es Pipeline Híbrido para IA Modular esto se debe por su flexibilidad, didáctica y escalable.


El flujo de procesamiento técnico está diseñado en Python y estructurado modularmente de la siguiente manera:

1. **Etapla Ingesta:** En esta etapa se extrae de forma automatizada el archivo fuente en formato CSV (02_Base_WA_Fn-UseC_-Telco-Customer-Churn.csv) alojado en (Data/Raw).




```
1 2026-05-24 19:42:44,530 - INFO - [Etapa 1 - Ingesta]: Iniciando Pipeline de Datos ....
2 2026-05-24 19:42:44,556 - INFO - [Etapa 1 - Ingesta]: RUN_ID: 4c5f2f6a-93d0-4b6c-b598-4bb8af9cde42 - Ingesta exitosa. Número de filas: 7043, Columnas: 21
3 2026-05-24 19:42:44,556 - INFO - [Etapa 1 - Ingesta]: RUN_ID: 4c5f2f6a-93d0-4b6c-b598-4bb8af9cde42 - Ingesta completada con éxito.
4
```

2. **Limpieza y Transformación:** En esta etapa se realiza la conversión de tipos de datos para las columnas TotalCharges y MonthlyCharge, corrigiendo de tipo texto a numérico flotante. Se eliminan registros vacíos introducidos de forma anómala y se anonimiza el campo de customerID.




```
1 2026-05-24 19:44:16,826 - INFO - [Etapa 2 - Limpieza y Transformación]: RUN_ID: e8a81754-62e0-4b62-8ff0-88a8888881ef - Iniciando limpieza y transformación de datos...
2 2026-05-24 19:44:16,871 - INFO - [Etapa 2 - Limpieza y Transformación]: RUN_ID: e8a81754-62e0-4b62-8ff0-88a8888881ef - Limpieza y transformación completada con éxito.
```

3. **Validación Estructural y Semántica:** En esta etapa se implementó una compuerta de calidad automatizada mediante la librería Pandera en Python. Su propósito es garantizar que el dataset de Telco Customer Churn cumpla de forma estricta con las especificaciones técnicas y las reglas lógicas del negocio antes de autorizar su persistencia en la base de datos.



```
1 2026-05-24 19:46:42,253 - INFO - [Etapa 3 - Validación]: Dataset cargado para inspección automatizada. Dimensiones: (7043, 21)
2 2026-05-24 19:46:42,321 - INFO - [Etapa 3 - Validación]: ¡COMPUERTA DE CALIDAD SUPERADA [PASSED]! El dataset cumple con todas las especificaciones.
3 2026-05-24 19:46:42,375 - INFO - [Etapa 3 - Validación]: Datos validados exitosamente guardados en 'Data/Processed/Validation/03_Validacion.csv'
```

4. **Carga de datos:** En esta etapa se exporta de forma automatizada el dataset limpio y validado a una base de datos relacional analítica dejándolo en un estado idóneo para el entrenamiento del modelo.



```
1 2026-05-24 19:48:36,629 - INFO - [Etapa 4 - Carga]: Iniciando carga por lotes (Batch) de 7043 registros a SQLite...
2 2026-05-24 19:48:37,052 - INFO - [Etapa 4 - Carga]: PROCESO DE PERSISTENCIA FINALIZADO.
3 2026-05-24 19:48:37,052 - INFO - [Etapa 4 - Carga]: Registros insertados exitosamente en la DB: 7043
4 2026-05-24 19:48:37,052 - INFO - [Etapa 4 - Carga]: Registros rechazados por la Compuerta de Calidad: 0
5
```

Plan de Seguridad entorno DataOps

Operar en un entorno chileno exige el cumplimiento de la Ley N° 19.628 sobre la Protección de Datos Personales.

Medidas Técnicas Implementadas:

Debido a que, el sistema contiene datos sensibles de los clientes se propone las siguientes medidas:

- **Enmascaramiento o Hash (SHA-256):** Aplicando criptografía a customerID para que no sea rastreable fuera del entorno analítico.
- **Control de Acceso:** Restricción de lectura al archivo raw solo a perfiles autorizados.
- **Seguridad en la Base de Datos:** Almacenamiento local seguro de la base de datos SQLite con permisos restringidos del sistema operativo.

Diseño Técnico del sistema

1. Descripción técnica del sistema

1.1 Componentes técnicos del sistema

- Script de ingesta de datos desde archivos CSV
- Script de limpieza y transformación de datos
- Script de validación de los datos
- Script para almacenamiento en base de datos
- Script para ejecutar todo el pipeline

1.2 Estructura General

La solución está estructurada de manera modular, con scripts separados por etapas del pipeline. Cada módulo cumple una función específica, facilitando la trazabilidad y el mantenimiento.

```
1  Modelo-Predictivo-TCC/
2  |— README.md
3  |— pyproject.toml
4  |— uv.lock
5  |— Dockerfile
6  |— Data/
7  |   |— Raw/
8  |   |   |— 02_Base_WA_Fn-UseC_-Telco-Customer-Churn.csv
9  |   |— Processed/
10 |   |   |— Ingesta/
11 |   |   |— Processing/
12 |   |   |— Validation/
13 |   |— Logs/
14 |   |   |— 01_Ingesta_Datos.log
15 |   |   |— 02_Limpieza_Transformacion.log
16 |   |   |— 03_Validacion.log
17 |   |   |— 04_Carga_Datos.log
18 |   |— Sql/
19 |   |   |— db_telco_churn.sqlite
20 |— Scripts/
21 |   |— Ingesta.py
22 |   |— LimpiezaTransformacion.py
23 |   |— Validacion.py
24 |   |— CargaDeDatos.py
25 |   |— Pipeline.py
26 |— ModelPredictive/
27 |— \\\
```

1.3 Tecnologías utilizadas

- **Python 3:** Lenguaje principal para la programación de todo el sistema.
- **VS Code:** Se eligió la IDE principal debido a, que es un editor de código ligero, gratuito y de alto rendimiento, además de su integración nativa con Git.
- **Librerías de Datos:** Pandas, NumPy, Logging, Hashlib y Pandera para el procesamiento y tratamiento de los datos
- **SQLite:** Base de datos relacional para el almacenamiento seguro de los datos procesados.
- **Scikit-Learn:** Librería de Inteligencia Artificial utilizada para entrenar, validar y evaluar el modelo predictivo de abandono (Churn).
- **GitHub:** Se utiliza Git debido a que es una plataforma que permite alojar repositorios Git permitiendo colaboración en equipo e integrar herramientas CI/CD.
- **GitHub Actions (CI/CD):** Se utiliza para automatizar los flujos de trabajo directamente desde el repositorio de GitHub. Permitiendo crear flujos de trabajo personalizados para compilar, probar y desplegar código automáticamente (CI/CD) cada vez que ocurre un evento, como subir código o crear un pull request.
- **Docker (Contenedorización):** Se eligió la imagen base python:3.13-slim para garantizar un entorno ligero y reproducible. Esto asegura que el modelo de IA o la lógica de datos se ejecute sin conflictos de dependencias, independientemente de la infraestructura subyacente.

1.4 Relación entre componentes


Los scripts se ejecutan en el siguiente orden: ingesta → limpieza y transformación → validación → carga de datos. Cada etapa depende de la salida de la anterior. El dataset limpio se guarda en SQLite y se utiliza luego en el modelado y visualización.

2. Diagrama técnico



3. Modelo de datos básico y diccionario

3.1 Modelo de datos



3.2 Diccionario de datos

Campo	Descripción
customerID	Identificador único del cliente.
gender	Género del cliente (Male/Female).
SeniorCitizen	Indica si el cliente es mayor de 65 años (0 = No 1 = Sí).
Partner	Indica si el cliente tiene pareja (Yes/No).
Dependents	Indica si el cliente tiene dependientes (Yes/No).
Tenure	Número de meses que el cliente ha permanecido en la compañía.
PhoneService	Indica si el cliente tiene servicio telefónico (Yes/No).
MultipleLines	Indica si el cliente tiene múltiples líneas telefónicas (Yes/No/No phone service).
InternetService	Tipo de servicio de internet (DSL, Fiber optic, No).
OnlineSecurity	Indica si el cliente tiene seguridad en línea (Yes/No/No internet service).
OnlineBackup	Indica si el cliente tiene backup en línea (Yes/No/No internet service).
DeviceProtection	Indica si el cliente tiene protección de dispositivo (Yes/No/No internet service).
TechSupport	Indica si el cliente tiene soporte técnico (Yes/No/No internet service).
StreamingTV	Indica si el cliente tiene streaming de TV (Yes/No/No internet service).
StreamingMovies	Indica si el cliente tiene streaming de películas (Yes/No/No internet service).
Contract	Tipo de contrato (Month-to-month, One year, Two year).
PaperlessBilling	Indica si el cliente tiene facturación sin papel (Yes/No).
PaymentMethod	Método de pago (Electronic check, Mailed check, Bank transfer, Credit card).
MonthlyCharges	Monto facturado mensualmente al cliente.
TotalCharges	Monto total facturado al cliente durante su permanencia.
Churn	Indica si el cliente abandonó el servicio (Yes/No).

4. README.md

<https://github.com/F4brizioGonzalez/Modelo-Predictivo-TCC.git>

Estrategia de KPI de Monitoreo

Nombre de KPI	Formula / Métrica	Umbral de Alerta Crítica
Integridad de Registros	$\frac{\text{Registros Finales Cargados}}{\text{Registros Iniciales Ingeridos}} \times 100$	Alerta si la pérdida por limpieza es > 2%
Detección de campos claves	Pruebas de nulos en campos "MonthlyCharges", "TotalCharges" y "Churn"	Alerta si se detecta un solo valor nulo
Latencia de ejecución	Tiempo total de procesamiento del Pipeline	Alerta si el tiempo total excede los 10 segundos

Conclusión

En conclusión, el desarrollo de este proyecto nos permitió diseñar una solución efectiva para uno de los mayores desafíos de la compañía de telecomunicaciones: la pérdida constante de clientes. Al automatizar la limpieza y organización de la información, logramos construir una base de datos sólida, segura y confiable.

Sobre esta base, la integración del modelo predictivo de Inteligencia Artificial marca la gran diferencia del proyecto, ya que nos permite encontrar patrones ocultos en el comportamiento de los usuarios y anticipar con precisión qué clientes tienen mayor riesgo de cancelar sus servicios.

Desde una perspectiva de negocio, este sistema transforma por completo la estrategia de la empresa. En lugar de actuar de forma reactiva cuando un cliente ya se ha ido, la compañía ahora cuenta con una herramienta proactiva para ofrecer soluciones personalizadas a tiempo. En definitiva, este proyecto no solo optimiza el manejo de los datos, sino que se convierte en una pieza clave para mejorar la retención de clientes, fortalecer su lealtad y proteger los ingresos de la organización.

Como próximos pasos estratégicos del proyecto, la solución evolucionará hacia una arquitectura en la nube mediante la migración del contenedor Docker actual a una infraestructura Cloud (como AWS o Azure), lo que permitirá automatizar la ejecución periódica de todo el pipeline e integrar herramientas de orquestación de datos. Asimismo, se implementará un sistema de monitoreo continuo para detectar la degradación del modelo a lo largo del tiempo y se desarrollará un dashboard analítico interno en Power BI orientado a la gerencia de marketing y retención. Finalmente, las predicciones probabilísticas de abandono generadas se consumirán de forma interna mediante la integración directa de la base de datos analítica con el CRM comercial de la compañía, permitiendo que los ejecutivos desplieguen campañas comerciales preventivas y personalizadas de manera oportuna.